

Proyecto final de Estadística

Análisis estadístico de una base de datos libre con enfoque de control de calidad, comparación de procesos o toma de decisiones

Modalidad	Grupos de 2 a 4 estudiantes
Producto principal	Informe técnico + archivo Excel
Base de datos	Libre, elegida por cada grupo
Extensión sugerida	6 a 10 páginas, sin contar anexos

Idea general. Cada grupo deberá seleccionar una base de datos libre, real o construida por ellos, y realizar un análisis estadístico completo que permita describir, comparar e interpretar un fenómeno. El proyecto debe usar las herramientas vistas en el curso: estadística descriptiva, gráficos, medidas de tendencia central, dispersión, posición, modelos probabilísticos, intervalos de confianza y pruebas de hipótesis.

1. Objetivo general

Aplicar herramientas estadísticas descriptivas e inferenciales para analizar una base de datos elegida libremente por los estudiantes, con el fin de extraer conclusiones justificadas, interpretar resultados y tomar una decisión basada en evidencia.

2. Temáticas posibles

La base de datos puede provenir de cualquier contexto académico, científico, social, industrial o cotidiano, siempre que permita aplicar las herramientas del curso. Algunos ejemplos son:

- control de calidad en un proceso químico, alimentario, farmacéutico o industrial;
- análisis de rendimiento académico de estudiantes;
- tiempos de atención en un servicio;
- producción, defectos o fallas en una línea de trabajo;
- datos ambientales: temperatura, lluvia, calidad del agua, contaminación, residuos;
- datos deportivos: rendimiento, tiempos, puntuaciones, frecuencia de eventos;
- datos de ventas, clientes, inventario o comportamiento de consumo;
- datos recolectados por encuesta, experimento o simulación.

Importante. La base de datos es libre. Sin embargo, debe tener suficiente riqueza estadística: variables cuantitativas, variables cualitativas, al menos dos grupos comparables y una pregunta clara de análisis.

3. Requisitos mínimos de la base de datos

La base de datos debe cumplir, como mínimo, con las siguientes condiciones:

1. Tener al menos **60 observaciones** o registros.

2. Incluir al menos **5 variables**.

3. Incluir al menos:

- 2 variables cuantitativas;
- 1 variable cualitativa nominal;
- 1 variable cualitativa ordinal o una variable categórica con orden natural;
- 1 variable que permita comparar grupos, por ejemplo: tratamiento, sexo, jornada, ciudad, lote, catalizador, método, grupo, nivel, categoría, etc.

4. Permitir construir al menos una variable tipo **éxito/fracaso** o **cumple/no cumple**. Por ejemplo:

$$\text{cumple} = 1 \quad \text{si rendimiento} \geq 78 \%,$$

o

$$\text{defectuoso} = 1 \quad \text{si tiempo} > 24 \text{ min.}$$

5. Permitir formular una pregunta de comparación. Por ejemplo:

- ¿Hay diferencia entre los promedios de dos grupos?
- ¿Hay diferencia entre las proporciones de cumplimiento de dos grupos?
- ¿Hay diferencia entre tres o más medias?
- ¿Cuál grupo parece más estable o conveniente?

4. Pregunta orientadora

Cada grupo debe formular una pregunta principal. Algunos ejemplos:

- ¿Cuál método produce mejores resultados promedio?
- ¿Qué grupo presenta menor variabilidad?
- ¿Hay diferencia estadísticamente significativa entre los grupos?
- ¿Cuál proceso tiene menor probabilidad de no conformidad?
- ¿Qué categoría presenta mayor tasa de cumplimiento?

La pregunta debe ser clara, responderse con los datos y conectarse con los análisis realizados.

5. Estructura del informe

El informe debe contener las siguientes secciones.

5.4 Limpieza y preparación de datos

Deben indicar si encontraron:

- datos faltantes;
- errores de digitación;
- valores atípicos;
- variables que tuvieron que recodificar;
- nuevas variables creadas, como `cumple`, `defectuoso`, `grupo`, etc.

6. Análisis descriptivo obligatorio

6.1 Tablas de frecuencia

Deben construir al menos:

- una tabla de frecuencias para una variable cualitativa;
- una tabla de frecuencias agrupadas para una variable cuantitativa.

Cada tabla debe incluir frecuencias absolutas, relativas y porcentajes. Para variables ordinales o cuantitativas agrupadas, también deben incluir acumuladas cuando aplique.

6.2 Gráficos

Deben incluir mínimo:

- un gráfico de barras;
- un gráfico circular o de sectores;
- un histograma;
- un polígono de frecuencias o un gráfico de líneas equivalente;
- un diagrama de caja y bigotes.

Cada gráfico debe tener título, etiquetas y una breve interpretación.

6.3 Medidas descriptivas

Para al menos dos variables cuantitativas deben calcular:

- media;
- mediana;
- moda, si aplica;
- rango;
- varianza;

- desviación estándar;
- coeficiente de variación;
- cuartiles Q_1, Q_2, Q_3 ;
- rango intercuartílico IQR ;
- percentiles relevantes, por ejemplo P_{10} y P_{90} .

7. Modelos probabilísticos y riesgo

Cada grupo debe incluir al menos dos de los siguientes componentes:

1. **Modelo normal:** estimar una probabilidad del tipo

$$P(X < a), \quad P(X > b), \quad P(a < X < b).$$

Por ejemplo, probabilidad de no cumplir una especificación.

2. **Puntaje z:** calcular e interpretar al menos dos valores estandarizados:

$$z = \frac{x - \bar{x}}{s}.$$

3. **Modelo binomial:** si hay una variable de cumplimiento/no cumplimiento, estimar una probabilidad como:

$$P(X \leq k), \quad P(X \geq k),$$

para un lote hipotético de tamaño n .

4. **Modelo Poisson:** si hay conteos de eventos, fallas, partículas, quejas o defectos por intervalo, estimar probabilidades como:

$$P(Y = 0), \quad P(Y \leq k), \quad P(Y \geq k).$$

8. Inferencia estadística obligatoria

El proyecto debe incluir los siguientes análisis inferenciales.

8.1 Intervalo de confianza

Construir al menos un intervalo de confianza del 95 % para:

- una media, usando distribución t ;
- o una proporción, usando aproximación normal.

Debe interpretarse en contexto.

8.2 Prueba de hipótesis

Realizar al menos una prueba de hipótesis con p-valor. Puede ser:

- prueba t de una muestra;
- prueba t de dos muestras;
- prueba z para una proporción;
- prueba z para dos proporciones.

Deben escribir:

H_0 , H_1 , α , p-valor, decisión.

8.3 Comparación de tres o más grupos

Si la base de datos tiene tres o más grupos comparables, deben realizar un ANOVA de un factor. Si no los tiene, deben justificar por qué no aplica y realizar una comparación alternativa entre dos grupos.

Para ANOVA deben incluir:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k,$$

H_1 : al menos una media es diferente.

También deben reportar:

- estadístico F ;
- p-valor;
- decisión;
- interpretación en contexto.

9. Conclusión final

La conclusión debe responder claramente la pregunta principal. Debe incluir:

- qué grupo, proceso, categoría o condición parece más conveniente;
- cuáles son los resultados estadísticos más importantes;
- qué limitaciones tiene el análisis;
- qué recomendación final hacen.

10. Archivo Excel

El archivo Excel debe estar ordenado en hojas. Se sugiere la siguiente estructura:

- Datos_originales
- Datos_limpios
- Frecuencias

- Graficos
- Descriptiva
- Probabilidad
- Inferencia
- Conclusiones

11. Recomendaciones finales

- No escojan una base de datos solo porque sea grande; debe permitir análisis estadístico.
- Eviten bases con solo texto o solo variables cualitativas.
- Revisen que haya grupos comparables.
- Escriban conclusiones en lenguaje claro: no basta con mostrar fórmulas.
- Si simulan datos, deben explicar claramente cómo lo hicieron y por qué.

Entrega final: informe en PDF + archivo Excel. La base de datos es libre, pero debe permitir aplicar de manera coherente las herramientas estadísticas vistas durante el curso.